

机器学习入门知识点完整汇总报告

理论与数学双层体系

学习整理

2026 年 7 月 31 日

摘要

本文完整系统整理机器学习入门全部核心知识，整体分为两大模块：第一部分为机器学习、深度学习、强化学习共用底层通用原理，包含三大分支定义、完整训练流程、前向/反向传播、收敛判定、评价指标、正则化与基础数学工具；第二部分由浅入深依次解析全部基础模型，从线性回归族、概率模型、树集成、无监督降维、基础神经网络到入门强化学习算法，全部配套严谨数学公式与理论解释，结构层次清晰。

1 第一部分机器学习通用底层基础原理

1.1 三大分支核心定义与底层逻辑

给定数据集 $D = \{(x_i, y_i)\}_{i=1}^N$ ，机器学习统一目标为学习映射 $f: \mathcal{X} \rightarrow \mathcal{Y}$ ，最小化全局预测误差，按照学习范式分为三类。

1.1.1 传统机器学习 (Machine Learning, ML)

理论定义：无需人工固化业务判别规则，模型从标注或无标注数据中自动学习输入输出内在规律，最终可泛化至从未见过的全新样本。

表 1: 机器学习三大学习范式对比

范式	数据形式	优化目标	典型任务
监督学习	输入 x + 真实标签 y	$\arg \min_f \mathcal{L}(f(x_i), y_i)$	回归、分类
无监督学习	仅输入 x ，无标签	挖掘数据分布、聚类结构	聚类、降维
半监督学习	少量标注 + 大量无标注	同时拟合标签与数据分布	半监督分类

1.1.2 1.1.2 深度学习 (Deep Learning, DL)

理论定义：机器学习子集，依靠多层嵌套非线性变换自动分层提取特征，免去人工特征工程。**数学复合映射：**

$$\hat{y} = f_{\text{out}}(W_L \cdot f_{L-1}(W_{L-1} \cdots f_1(W_1 x + b_1) \cdots + b_{L-1}) + b_L)$$

式中 f_k 为第 k 层激活函数， W, b 为网络待优化权重、偏置参数。

1.1.3 1.1.3 强化学习 (Reinforcement Learning, RL)

理论定义：无固定静态数据集，智能体 (Agent) 与环境持续交互，依靠奖励信号试错学习最优动作策略。数学核心五元组：($\mathcal{S}, \mathcal{A}, P, R, \gamma$)

- $\mathcal{S}$ ：状态空间； $\mathcal{A}$ ：动作空间；
- $P(s'|s, a)$ ：状态转移概率； R_t ： t 时刻即时奖励；
- $\gamma \in [0, 1]$ ：折扣因子，平衡短期与长期回报；

优化目标：最大化长期累积回报

$$G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k}$$

1.2 1.2 模型完整训练全流程 (理论 + 数学)

1.2.1 1.2.1 数据集划分 (数学约束)

数据集严格划分三类，样本无交集、满足独立同分布，严格杜绝数据泄漏：

1. 训练集 D_{train} ：用于更新模型参数 W, b ；
2. 验证集 D_{val} ：超参调优、早停、模型筛选；
3. 测试集 D_{test} ：仅训练结束后单次使用，评估真实泛化能力。

1.2.2 1.2.2 损失函数 Loss Function

理论：量化单个样本预测值与真实标签的偏差，是反向传播的优化目标。通用形式 $\mathcal{L}(\hat{y}, y)$ 。

回归 MSE 损失：
$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

二元交叉熵损失：
$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)]$$

1.2.3 1.2.3 代价函数 Cost Function

代价函数为全数据集损失均值，训练核心极小化目标：

$$J(W, b) = \frac{1}{N} \sum_{i=1}^N \mathcal{L}(f(x_i; W, b), y_i), \quad \arg \min_{W, b} J(W, b)$$

1.2.4 1.2.4 前向传播 Forward Propagation

数据从输入层流向输出层，仅计算预测与损失，不更新参数。单层网络计算流程：

$$z = Wx + b, \quad a = \sigma(z)$$

多层嵌套迭代得到最终预测 $\hat{y}$ ，再计算全局代价 J 。

1.2.5 1.2.5 反向传播 Back Propagation

基于微分链式法则反向求导，求解代价对参数梯度，用于参数更新：

$$\frac{\partial J}{\partial W} = \frac{\partial J}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial W}$$

1.2.6 1.2.6 梯度下降优化器通用公式

$$W \leftarrow W - \alpha \nabla_W J$$

α 为学习率；主流变体：批量梯度下降 BGD、随机梯度下降 SGD、Mini-Batch SGD、自适应 Adam 优化器。

1.2.7 1.2.7 收敛 Convergence 定义与判定

定义：迭代后验证误差、参数梯度不再显著波动，训练达到稳定。判定条件二选一：

1. 连续多轮 epoch 满足 $|J_{\text{val}, t+1} - J_{\text{val}, t}| < \varepsilon$ (ε 极小阈值)；
2. 参数梯度范数 $\|\nabla J\| \approx 0$ ，抵达局部极小区域。

三类收敛结果：理想恰当拟合、过拟合、欠拟合。

1.2.8 1.2.8 三大拟合状态

- 欠拟合：模型容量小于数据复杂度，训练、测试误差均偏高；
- 恰当拟合：训练、测试误差均低，差距很小；
- 过拟合：模型容量过大，记忆训练噪声，训练误差持续下降、测试误差上升；

过拟合抑制手段：L1/L2 正则、Dropout、早停、数据增强。

1.3 1.3 模型基础衡量指标

1.3.1 1.3.1 回归评价指标

表 2: 回归任务评价指标汇总

指标	数学公式	作用说明
MSE 均方误差	$\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2$	对大误差惩罚更强
MAE 平均绝对误差	$\frac{1}{N} \sum_{i=1}^N \hat{y}_i - y_i $	抗异常离群值
R^2 决定系数	$1 - \frac{\sum (\hat{y} - \bar{y})^2}{\sum (\bar{y} - y)^2}$	$(-\infty, 1]$, 越接近 1 拟合越好

1.3.2 1.3.2 分类基础指标

混淆矩阵基础: TP 真阳、 FP 假阳、 TN 真阴、 FN 假阴。

$$\begin{aligned} \text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN}, & \text{Precision} &= \frac{TP}{TP + FP} \\ \text{Recall} &= \frac{TP}{TP + FN}, & F1 &= \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \end{aligned}$$

多分类均衡指标: Macro-F1、Micro-F1。

1.3.3 1.3.3 泛化误差

分为训练误差、验证误差、测试误差; 泛化误差等价于测试集误差, 衡量模型在未知样本的预测能力。

1.4 1.4 正则化、激活函数与底层数学工具

1.4.1 1.4.1 正则化项

- L2 正则 (权重衰减): $J_{\text{reg}} = J + \frac{\lambda}{2} \|W\|_2^2$, 平滑约束所有权重;
- L1 正则: $J_{\text{reg}} = J + \lambda \|W\|_1$, 产生稀疏权重, 自动筛选特征;

1.4.2 1.4.2 基础激活函数

无激活时多层网络等价纯线性模型, 无法拟合非线性分布:

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \text{ReLU}(z) = \max(0, z)$$

Sigmoid 易梯度消失, ReLU 为工业主流激活。

1.4.3 1.4.3 底层数学基础

矩阵运算、偏导数与梯度、概率分布、期望、方差、极大似然估计 (MLE)。

2 第二部分经典基础模型理论与数学解析

2.1 2.1 线性模型家族

2.1.1 2.1.1 多元线性回归

模型: $\hat{y} = \mathbf{W}^T \mathbf{X} + b$, 损失 MSE。代价:

$$J(W, b) = \frac{1}{2N} \sum_{i=1}^N (\mathbf{W}^T \mathbf{x}_i + b - y_i)^2$$

两种求解:

1. 闭式正规方程: $\mathbf{W} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ (小数据集);
2. 梯度下降迭代 (大规模数据)。

仅拟合线性关系, 可拓展岭回归、Lasso。

2.1.2 2.1.2 岭回归 Ridge (L2 正则线性回归)

$$J = \frac{1}{2N} \sum (\hat{y} - y)^2 + \frac{\lambda}{2} \|\mathbf{W}\|_2^2$$

缓解特征多重共线性, 限制权重幅值爆炸。

2.1.3 2.1.3 Lasso 回归 (L1 正则线性回归)

$$J = \frac{1}{2N} \sum (\hat{y} - y)^2 + \lambda \|\mathbf{W}\|_1$$

L1 在原点处梯度不连续, 可将冗余特征权重置 0, 实现自动特征筛选。

2.1.4 2.1.4 多项式回归

对原始特征构造高次项, 参数仍为线性, 单变量二次形式:

$$\hat{y} = w_0 + w_1 x + w_2 x^2$$

阶数过高极易过拟合, 必须搭配正则约束。

2.1.5 2.1.5 逻辑回归（二分类广义线性模型）

$$z = \mathbf{W}^T \mathbf{x} + b, \quad \hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}}$$

损失二元交叉熵，无解析闭式解；多分类拓展 Softmax 回归。

2.2 2.2 非参数与概率生成模型

2.2.1 2.2.1 K 近邻 KNN

惰性无训练模型，预测取距离最近 k 个样本投票/均值。欧氏距离：

$$d(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{\sum_{j=1}^D (x_{1j} - x_{2j})^2}$$

超参 k ：过小过拟合、过大欠拟合，预测速度慢。

2.2.2 2.2.2 朴素贝叶斯 Naive Bayes

贝叶斯公式 + 特征条件独立假设：

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}, \quad P(X_1, X_2|Y) = P(X_1|Y)P(X_2|Y)$$

高斯朴素贝叶斯适配连续特征；多项式朴素贝叶斯用于文本分类，训练速度快。

2.3 2.3 树模型与集成学习

2.3.1 2.3.1 决策树 Decision Tree

递归划分特征空间，分类分裂准则信息熵：

$$H = - \sum_c p_c \log p_c$$

通过限制树深、叶子最小样本抑制过拟合，可解释性极强。

2.3.2 2.3.2 随机森林 Random Forest

并行训练多棵独立决策树，样本、特征随机采样，投票输出，降低单树方差。

2.3.3 2.3.3 GBDT/XGBoost/LightGBM 梯度提升树

串行训练，每一棵树拟合前一轮残差；目标内置 L2 正则，结构化表格数据最优基础模型。

2.4 2.4 无监督降维：PCA 主成分分析

线性无监督降维，求解协方差矩阵 $\mathbf{X}^T \mathbf{X}$ 的特征值、特征向量，选取前 k 个最大特征向量作为投影基，保留数据最大方差，去除特征冗余、可视化高维数据。

2.5 2.5 基础神经网络模型

2.5.1 2.5.1 单层感知机

$$\hat{y} = \text{sign}(\mathbf{W}\mathbf{x} + b)$$

仅处理线性可分样本，无法解决异或非线性问题。

2.5.2 2.5.2 MLP 多层全连接网络

多层线性变换叠加非线性激活，万能逼近定理可拟合任意连续函数；前向传播计算预测，反向传播梯度下降训练，搭配 ReLU、Dropout。

2.5.3 2.5.3 CNN 卷积神经网络

核心操作卷积、池化下采样；卷积层权重共享，大幅减少参数量，专门处理图像网格数据，分层提取局部视觉特征。

2.5.4 2.5.4 RNN/LSTM 时序循环网络

时序递推公式：

$$h_t = \sigma(W_h h_{t-1} + W_x x_t + b)$$

基础 RNN 长序列梯度消失；LSTM 依靠输入/遗忘/输出门捕获长期时序依赖，适配文本、时间序列。

2.6 2.6 入门强化学习算法

2.6.1 2.6.1 Q-learning (无模型值迭代)

贝尔曼更新公式：

$$Q(s, a) \leftarrow Q(s, a) + \alpha [R + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

2.6.2 2.6.2 Policy Gradient 策略梯度

不拟合价值函数，直接优化动作概率分布，最大化长期累积回报，适配连续动作空间任务。